



Maxun (bk-maxun)

技術仕様書

オープンソース ノーコード WEBデータ抽出プラットフォーム

REPOSITORY

github.com/BKStock/bk-maxun

VERSION

v0.0.34

LICENSE

AGPL-3.0

Maxunとは何か

Webをデータベースへ

Maxunは、Webサイトを構造化されたAPIやデータソースに変換する**オープンソースのノーコードプラットフォーム**です。コードを一切書かずに、ポイント＆クリック操作やAIの自然言語指示でWebデータを収集・整理できます。

誰でも使える設計

開発者だけでなく、非エンジニアのビジネスユーザーも利用可能。

- ✓ リード生成
- ✓ 市場調査・価格モニタリング
- ✓ コンテンツ集約・競合分析

15,200+

 GITHUB STARS

100M+

 ROWS EXTRACTED

v0.0.34

 CURRENT VERSION

5つのコア機能エコシステム

Extract

ユーザー操作をエミュレートして構造化データを収集。Recorder ModeとAI Modeの2方式を提供。

主な用途

商品リスト、求人、レビューなどの抽出

Scrape

WebページをクリーンなMarkdownまたはHTMLに変換。スクリーンショット取得も可能。

主な用途

AIワークフロー向けのデータ準備

Crawl

Webサイト全体をクロールし、全ページからコンテンツを抽出。探索範囲を制御可能。

主な用途

サイト全体の収集、SEO分析

Search

自動検索で結果を収集。

主な用途

トレンド調査、競合モニタリング

SDK

開発者向けのスクレイピング／自動化ツールキット。

主な用途

プログラム統合、CI/CDパイプライン

Extract機能 — Recorder Mode と AI Mode




Recorder Mode

ユーザーがブラウザ上で行う操作（クリック、スクロール、ナビゲーション）をそのまま記録し、再利用可能な「ロボット」に自動変換します。

USE CASE DEMO

Airbnbで物件リストを閲覧する操作を記録するだけで、10件の物件情報を抽出するロボットが完成。



AI Mode

自然言語で「何を抽出したいか」を記述するだけで、LLMが自動的にページ構造を解析し、データ抽出を実行します。Anthropic AI SDKを統合。

USE CASE DEMO

IMDbのページで「トップ50映画の名前・評価・上映時間を抽出して」と指示するだけで完了。

共通機能



ページネーション自動処理



無限スクロール対応



レイアウト変更への自動適応

Scrape・Crawl・Search — 多角的なデータ収集



Scrape

単一ページの高品質変換

指定URLのWebページ全体をクリーンなMarkdownまたはHTMLに変換します。スクリーンショット取得や不要要素の除去で、LLMが理解しやすい形式に整形します。

AIエージェント / RAG

ドキュメントアーカイブ

Markdown変換

Screenshot



Crawl

Webサイト全体の自動巡回

起点URLからリンクを辿り、Webサイト全体を自動的に巡回してコンテンツを抽出します。深度や範囲を細かく設定可能です。

サイト全体収集

SEO分析

深度制御

スコープ設定



Search

検索エンジン連動データ発見

Google等の検索を自動操作し、キーワードに基づく検索結果を収集します。時間フィルターで最新トピックのモニタリングに適します。


トレンド調査

競合モニタリング

Google検索自動化

時間フィルター

システムアーキテクチャ（Docker Compose構成）



BackendはPlaywrightを内蔵しメモリ制限6GB・共有メモリ2GBで動作。Browserサービスはメモリ2GB・CPU 1.5コア制限で分離運用。

技術スタック

TypeScript 93.3% Modern Stack



Frontend

- **React 18 + TypeScript**
UIライブラリ & 型安全性
- **Vite 5.4**
高速ビルドツール
- **MUI (Material-UI) 5**
UIコンポーネント
- **@tanstack/react-query**
サーバー状態管理
- **rrweb**
セッション録画・再生



Backend

- **Express.js + TypeScript**
REST APIサーバー
- **PostgreSQL 13 + Sequelize**
RDBMS & ORM
- **PgBoss + node-cron**
ジョブキュー & スケジューリング
- **Socket.io**
リアルタイム双方向通信
- **Swagger**
APIドキュメント自動生成



Automation

- **Playwright**
クロスブラウザ自動化エンジン
- **maxun-core v0.0.32**
独自スクレイピングコア
- **@anthropic-ai/sdk**
AI抽出機能連携
- **Winston**
構造化ロギング

バックエンドの内部モジュール構成

📦 CORE COMPONENTS

📁 `api/`

RESTful APIエンドポイント定義。コントローラーロジックを含む。

📁 `routes/`

Expressルーター設定。APIパスとコントローラーの紐付け。

📁 `models/`

Sequelizeデータモデル。ロボット、実行履歴、ユーザー等の定義。

📁 `db/`

データベース接続設定およびマイグレーションスクリプト。

🧩 FEATURE MODULES

📁 `browser-management/`

Playwrightインスタンスの生成・管理・終了処理。

📁 `workflow-management/`

ロボットのワークフロー実行制御、rrwebライブ録画処理。

📁 `markdownify/`

HTML→Markdown変換エンジン（Scrape機能の中核）。

📁 `sdk/`

外部SDK向けAPIインターフェースの実装。

⚙️ WORKERS & SERVICES

📄 `mcp-worker.ts`

Model Context Protocol (MCP) 対応ワーカー。AI連携用。

📄 `pgboss-worker.ts`

PgBossジョブキューワーカー。非同期タスクの処理。

📄 `schedule-worker.ts`

cron式に基づくスケジュール実行管理ワーカー。

📁 `socket-connection/`

WebSocket接続管理。リアルタイムな状態通知と通信。

豊富な外部連携 — API・Webhook・サードパーティ統合



Data Export

- ✓ **Google Sheets**
OAuth連携でスプレッドシートへリアルタイム同期
- ✓ **Airtable**
データベースへの直接エクスポート



Dev Interface

- ✓ **RESTful API**
Swagger UIで自動ドキュメント化された全機能API
- ✓ **Webhooks**
イベント駆動型のシステム連携
- ✓ **SDK**
プログラマティックな制御用キット



AI Ecosystem

- ✓ **MCP Server内蔵**
Model Context Protocol対応
- ✓ **AI Agent連携**
LangChain, OpenAI, n8n等のワークフローに組み込み可能



STEALTH MODE (ANTI-BLOCKING)



Proxy Rotation



CAPTCHA Bypass



Fingerprint Protection

セットアップ — Docker Composeで簡単デプロイ

Docker Compose (推奨)

リポジトリ内の設定ファイルを使用し、1コマンドで全5サービスを一括起動できます。

```
$ docker-compose up -d
```

Access Points

Frontend UI	http://localhost:5173
Backend API	http://localhost:8080
MinIO Console	http://localhost:9001

Manual Setup (Docker不使用)

Node.js, PostgreSQL, MinIO, Redisを個別にインストールし、以下の手順で起動します。

```
$ npm install && npx playwright install --with-deps chromium && npm run start
```

必須環境変数 (.env)

```
DB_HOST / DB_PORT / DB_USER
```

```
JWT_SECRET
```

```
ENCRYPTION_KEY
```

```
MINIO_ENDPOINT / MINIO_ACCESS_KEY
```

※ Google OAuth, Airtable連携, テレメトリ設定はオプションです。

 クラウドホスト版も利用可能

app.maxun.dev →

Auto Robots — 事前構築済みロボットで即座にデータ収集



Medium

特定のユーザープロフィールから公開されているストーリー一覧を抽出します。

タイトル

公開日

拍手・コメント数



IMDb

指定したジャンルの人気映画ランキング情報を抽出します。

映画タイトル

評価スコア

公開年

監督



Google Trends

指定した地域における検索トレンドデータを抽出します。

トレンドワード

検索ボリューム

関連トピック



Craigslist

地域・業種・キーワードに基づいて求人情報を抽出します。

職種名

給与

勤務地

投稿日時



YouTube

キーワード検索結果から動画リスト情報を抽出します。

動画タイトル

再生回数

チャンネル名

URL



Airbnb

場所、日付、人数条件に合致する宿泊施設リストを抽出します。

物件名

価格/泊

評価

アメニティ



これらのロボットはテンプレートであり、自社の要件に合わせてパラメータや抽出ロジックを自由にカスタマイズ可能です。

セキュリティ設計 — 認証・暗号化・アクセス制御



JWT Authentication

JSON Web Tokenによるステートレス認証を採用。セッションシークレットによる署名を併用し、改ざんを防止します。

`jsonwebtoken`



Data Encryption

環境変数 `ENCRYPTION_KEY` を使用して、プロキシ設定やAPIキーなどの機密データをAES暗号化して保存します。

`AES-256-CBC`



Password Hashing

bcryptアルゴリズムを使用してパスワードをハッシュ化。データベース内にプレーンテキストで保存されることはありません。

`bcrypt`



CSRF Protection

csrfミドルウェアを実装し、クロスサイトリクエストフォージェリ攻撃からAPIエンドポイントを保護します。

`csrf middleware`



Secure Login Scraping

ブラウザセッション（Cookie/Storage）を同期する仕組みにより、パスワードを共有することなく、ログインが必要なサイトからのデータ抽出を実現します。

`Session Sync`

まとめ — Maxunの価値と活用可能性



No-Code Ecosystem

Extract, Scrape, Crawl, Search, SDKの5つの柱で、あらゆるWebデータ収集ニーズに対応。直感的に操作可能なUIを提供。



Modern Tech Stack

TypeScript, React, Playwright, Dockerによる堅牢で保守性の高いアーキテクチャ。社内統合も容易。



AI & Integration

MCP対応のAI連携、Google Sheets/Airtableへのエクスポートで既存ワークフローに組み込み可能。



Future Growth

活発なOSSコミュニティと急速な機能拡張。GitHub Starsの実績が成長を裏付け。

Maxunは、社内のWebデータ収集・自動化ニーズに対する
強力かつ柔軟なソリューションとなり得る有力な選択肢です。